

Hissə C - Analitik Hesabat

C1. Çətinliklər və həllər:

- Dataset ilə bağlı bəzi problemlər yaşadım. Tapşırıqda qeyd olunan Mozilla Common Voice dataset-i Mozilla tərəfindən artıq internetdə paylaşılır. Bu dataset-i yükləmək üçün isə Dataset kitabxanasının son versiyası uyğun olmadı.
- Mozilla Common Voice dataset-i uyğun olmadığından, başqa bir dataset, yeni Google Fleurs datasetindən istifadə etmək qərarına gəldim. Dataset kitabxanasının versiyası düzgün olmadığı üçün, Dataset kitabxanasının 2.21.0 versiyasını əlavə etdim.
- Azərbaycan dili bir kök sözə onlarla şəkilçi əlavə oluna bilər. Bu, söz lüğətini genişləndirir və modelin söz formalarını tanıması çətinləşir. Bundan əlavə, Azərbaycan dilinə aid açıq məlumat bazaları məhduddur, bu da pretrain mərhələsində dilin az təmsil olunmasına səbəb olur. Xarici mənşəli şəxs adları və coğrafi adlar isə fonetik cəhətdən tamamilə fərqli tələffüz edilir.

C2. Nəticələrin Təhlili

- Whisper-small modelinin WER nəticə 59.2%-dir. Nəzərə alsaq ki, Azərbaycan dili az təmsil olunub, buna görə də nəticə qəbul etmək olar. Fine-tuning sonrası WER 53.5%-ə endi. Bu, pipeline-ın düzgün qurulduğunu sübut edir. Daha böyük fine-tuning dataseti və daha güclü model (whisper-large-v3) istifadə edilsəydi, nəticə daha da yaxşılaşa bilərdi.
- Nəticələrdən görünür ki, model əsasən üç növ səhv edir. Birincisi leksik səhvlərdir, xarici mənşəli şəxs adları və coğrafi adlar yanlış tanınır. İkincisi fonetik səhvlər, oxşar səslənən sözlər səhv salınır. Üçüncüsü şəkilçi səhvlərdir, söz sonluqları yanlış tanınır.
- Model qısa, sadə cümlələrdə, aydın tələffüzlə və az xarici söz olan mətnlərdə daha yaxşı işləyir. Uzun, mürəkkəb cümlələrdə və çoxlu xarici ad olan mətnlərdə və terminologiya olan audio nümunələrində isə model daha pis nəticə göstərir.

C3. Yaxşılaşdırma Yolları

- Production mühitinə keçid üçün bir neçə əsas addım lazımdır. Birincisi modeli tam dataset üzərində fine-tune etmək və daha güclü GPU-da whisper-large-v3 modeli ilə yenidən öyrətmək lazımdır. İkincisi modeli TensorRT formatına çevirərək inferens sürətini artırmaq lazımdır. Dördüncüsü modelin davamlı monitorinqi və yeni Azərbaycan dili məlumatları ilə mütəmadi yenilənməsi təmin edilməlidir.
- Birinci addım whisper-large-v3 modelini tam FLEURS dataseti üzərində fine-tune etmək. İkinci addım Azərbaycan dili üçün xüsusi dil modeli ilə Whisper-i birləşdirmək. Bu, şəkilçi səhvlərini və leksik xətalrı əhəmiyyətli dərəcədə azaldır. Üçüncü addım açıq mənbəli Azərbaycan dili datasetlərini birləşdirərək daha böyük və müxtəlif dataset yaratmaqdır.
- Azərbaycan dilinin aqlütinativ quruluşu və resurslarının məhdudluğu mövcud nitq tanıma modellərinin bu dildə kifayət qədər dəqiq işləməsinə imkan vermir.